

图神经网络预测烃类工质的热力学性质

洪小东¹, 董轩², 林美金², 廖祖维², 任聪静³, 杨遥², 蒋斌波², 王靖岱², 阳永荣²

(¹ 浙江大学杭州国际科创中心, 化工功能材料智能设计与制造浙江省工程研究中心, 浙江 杭州 311215; ² 浙江大学化学工程联合国家重点实验室, 浙江 杭州 310027; ³ 浙江大学宁波科创中心, 浙江 宁波 315100)

摘要: 有机朗肯循环(ORC)因其低温热电转换的能力而备受关注, 寻找高效环保工质, 以代替具有较高全球变暖潜能值(GWP)的氢氯氟烃(HCFC)和氢氟烃(HFC), 是推动 ORC 应用的重要任务之一。构建一个基于图神经网络(GNN)的 ORC 烃类工质热力学性质预测模型, 通过图神经网络学习分子结构的特征, 并将分子结构信息与温度结合, 利用多层感知机(MLP)构建热力学性质预测模型。模型基于 2508 种 C₂~C₁₀ 的链状烃、环烃和芳香烃分子构建训练集, 所得模型在预测临界温度、蒸发焓、气相摩尔热容和液相摩尔热容上均取得良好效果, 优于文献的预测效果。此外, 应用所得模型预测了超 43 万个氢氟烯烃(HFO)的热力学性质。

关键词: 热力学性质; 预测; 神经网络; ORC 工质; 氢氟烯烃

中图分类号: TQ 021.8

文献标志码: A

文章编号: 0438-1157 (2023) 11-4466-09

Prediction of thermodynamic properties of hydrocarbon working fluids by graph neural network models

HONG Xiaodong¹, DONG Xuan², LIN Meijin², LIAO Zuwei², REN Congjing³, YANG Yao², JIANG Binbo², WANG Jingdai², YANG Yongrong²

(¹ Engineering Research Center of Functional Materials Intelligent Manufacturing of Zhejiang Province, ZJU—Hangzhou Global Scientific and Technological Innovation Center, Zhejiang University, Hangzhou 311215, Zhejiang, China; ² State Key Laboratory of Chemical Engineering, Zhejiang University, Hangzhou 310027, Zhejiang, China; ³ Ningbo Innovation Center, Zhejiang University, Ningbo 315100, Zhejiang, China)

Abstract: Organic Rankine cycle (ORC) has attracted much attention due to its ability to convert low-grade heat to electricity. One of the important tasks to promote the application of ORC is to find efficient and environmentally friendly working fluids to replace high-GWP (global warming potential) hydrochlorofluorocarbon (HCFC) and hydrofluorocarbon (HFC). In this article, a prediction model for the thermodynamic properties of ORC hydrocarbon working fluids based on graph neural networks (GNN) is constructed. GNN is used to learn the characteristics of molecular structure, and the combination of molecular structure characteristics and temperature is used to build a prediction model of molecular structure and properties using multilayer perceptron (MLP). The model is based on a training set of 2508 linear, cyclic, and aromatic hydrocarbons with carbon chain lengths ranging from 2 to 10. The

收稿日期: 2023-09-11 修回日期: 2023-11-14

通信作者: 廖祖维(1980—), 男, 博士, 教授, liaozw@zju.edu.cn

第一作者: 洪小东(1991—), 男, 博士, 研究员, hongxiaodong@zju.edu.cn

基金项目: 国家自然科学基金项目(U22A20415); 浙江省尖兵领雁计划项目(2022C01SA442617)

引用本文: 洪小东, 董轩, 林美金, 廖祖维, 任聪静, 杨遥, 蒋斌波, 王靖岱, 阳永荣. 图神经网络预测烃类工质的热力学性质[J]. 化工学报, 2023, 74(11): 4466-4474

Citation: HONG Xiaodong, DONG Xuan, LIN Meijin, LIAO Zuwei, REN Congjing, YANG Yao, JIANG Binbo, WANG Jingdai, YANG Yongrong. Prediction of thermodynamic properties of hydrocarbon working fluids by graph neural network models[J]. CIESC Journal, 2023, 74(11): 4466-4474

obtained model achieves better prediction results than previous literature on predicting critical temperature, evaporation enthalpy and gas-phase and liquid-phase molar heat capacity. In addition, the resulting model was applied to predict the thermodynamic properties of over 430000 hydrofluoroolefins.

Key words: thermodynamic properties; prediction; neural network; ORC working fluids; hydrofluoroolefin

引 言

随着社会经济的快速发展与人口数量的不断攀升,对能源的需求也日益增加。世界各国正在积极部署基于可再生能源的低碳技术,以降低大气中的二氧化碳浓度^[1-2]。由于可再生能源固有的不稳定特性,其应用仍受到较多制约,全球能源结构依然以化石能源为主。工业生产过程中会产生大量废热^[3],废热通过空气或冷却水直接排放到大自然中,占比达输入能量的40%~60%,造成了大量的能源浪费。有机朗肯循环(organic Rankine cycle, ORC)适用于回收100~300℃的余热,近年来,因其低温热电转换的能力而备受关注^[4]。随着各国对碳排放的重视,ORC逐渐应用于太阳能^[5]、生物质能^[6]、地热能^[7]和工业废热^[8],具有很大的发展潜力。

ORC的工质选择是ORC过程最重要的优化参数之一^[9-11]。王羽鹏等^[12]基于神经网络-基团贡献法,获得21种工质在1584组工况下的ORC系统性能,工质在不同工况下的性能差异较大。李子航等^[13]模拟和分析了采用非共沸混合工质的亚临界ORC的热经济性。氢氯氟烃(hydrochlorofluorocarbon, HCFC)和氢氟烃(hydrofluorocarbon, HFC)是当前ORC工质常用的类别,但是,它们具有较高的全球变暖潜能值(global warming potential, GWP)。随着全球对温室气体排放的进一步限制,在未来数十年内这些工质将被逐步淘汰,寻找高效环保工质是推动ORC应用的关键^[14]。

氢氟烯烃(hydrofluoroolefin, HFO)在大气中的寿命极短,易分解,具有极小的GWP,因此被认定为第四代工质^[15]。但是,当前关于HFO热力学性质的数据非常有限。通过实验手段测量不同物理环境下的性质往往耗费巨大,数据缺失阻碍了对HFO的应用探索。尽管近几十年来计算化学取得了长足的进步,已经可以使用分子动力学模型预测分子的热力学性质^[16],但是对于数十万、百万潜在分子,仍需耗费大量的计算资源。

数据驱动的机器学习方法是当前广泛使用的

研究范式,已经在分子性质^[17-19]和材料性能^[20-22]预测等领域取得众多成果。Schweidtmann等^[23]提出一个数据驱动的图神经网络(graph neural networks, GNN)模型,用于预测燃料辛烷值,预测模型的确定系数(R^2)达到0.9以上。Liu等^[24]建立了一个高性能的变分自编码器生成模型,能够有效地捕捉烃类分子的特征,可将其可逆地编码成高保真度的100维实值向量,并通过联合训练多层感知器,能够快速且准确地预测能量属性。针对分子的热力学性质预测,Alshehri等^[25]构建一种结合机器学习和基团贡献法的纯组分性质模型,可以预测25种性质,包括临界温度、临界压力、蒸发焓等。Yan等^[26]提出了一组原子分布矩阵和范数描述符,基于此建立一个统一的构效关系模型,用于预测14类有机化合物(例如,链状和环状烃类、醇、酮、羧酸)的四种性质,包括标准蒸发焓和气液固的生成焓。Aouichaoui等^[27]扩展了可解释GNN模型的功能,用于描述各种纯化物性质,创建了一个包含30种性质的数据库和预测模型,适用于计算机辅助分子设计,模型强调了在各种性质上进行全面模型评估以确保热力学一致性的重要性。Wang等^[28]提出基于GNN的分子对比学习方法,采用对比估计器来最大化相同分子的增强一致性,同时最小化不同分子的一致性,该对比学习框架显著提高了各种分子性质基准测试的性能。

当前,关于ORC工质的研究主要集中于对已有工质的系统评价和筛选,新型工质的开发面临物性缺失的问题。无法获得热力学性质缺失的新型工质在ORC中的关键性能指标。当前,针对ORC新型工质HFO的性质预测模型尚未开展大量研究,特别是摩尔热容和蒸发焓等影响ORC效率的性能。本研究构建一个基于多维图神经网络(k -GNN^[29])的HFO热力学性质预测模型。GNN用图形表示分子,其中原子和化学键分别通过图形中的节点和边表示,图形包含所代表分子的元素、结构等信息。GNN在监督学习中使用反向传播算法训练,获得基于分子图的热力学预测模型。此外,本研究将温度信息与分子图信息结合,从而获得可以预测不同温

度热力学性质的模型,这种端到端的学习方法消除了选择分子描述符或使用基团的需求。

1 数据集构建

目前 NIST (national institute of standards and technology) 和 DIPPR (design institute for physical properties) 物性数据集中仅包含 20 多种 HFO, 基于如此小规模的数据集无法构建有使用价值的预测模型。为了丰富数据库的内容, 收集了含有 C、H 和 F 元素的烃类化合物数据, 还添加了含有 C、H、F 和 Cl 元素的烃类化合物数据。这些分子同样包含了 HFO 中所共有的基团, 例如 C=C 键等。数据集包括 2508 个 C₂~C₁₀ 的链状烃、环烃和芳香烃分子。以该数据集为训练集, 构建 GNN 性质预测模型, 可以获得不同基团和元素对性质的影响, 从而利用非 HFO 分子的数据, 提高模型在 HFO 性质预测上的精度。

数据集包括每个分子用于 Peng-Robinson 状态方程的参数, 包括临界温度 T_c 、临界压力 P_c 、偏心因子 ω 以及 Aly 常数和 Lee 常数。根据数据集中各分子的状态方程参数, 可计算分子在不同温度下的热力学数据, 如气相摩尔热容、液相摩尔热容、蒸发焓等。本研究构建的数据集如表 1 所示, 数据集#1 为 2508 个分子和其临界温度 (T_c), 数据集#2 包括 44717 组数据, 为 2508 个分子在不同温度下的蒸发焓 (H_{eva})。同理, 数据集#3 和#4 为 2508 个分子在不同温度下的气相摩尔热容 (C_{pg}) 和液相摩尔热容 (C_{pl})。ORC 流程的操作压力通常低于工质的临界

压力, 所以数据集仅包含低于临界温度下的蒸发焓、气相摩尔热容和液相摩尔热容。此外, 基于所构建数据集开发的模型, 适用于包含表 2 中基团、表 3 中节点特征和表 4 中边特征的分子。

2 图神经网络

2.1 分子图形表示

任何分子都可以表示为分子图, 其中节点 $w, v \in V$ 代表原子。边 $e_{wv} \in E$ 代表两个原子之间的键。此外, 每个节点和每条边均由一个特征向量表征。节点特征向量 $f^v(v)$ 包含原子类型 (如 C、O 原子)、轨道杂化 (如 sp^3 、 sp^2)、是否成环、成键数目等信息, 为了减小分子图, 通常将氢原子隐含地包含在重原子的节点特征向量中, 统计为每个重原子连接的氢原子数目, 从而得到一个去氢原子分子图。边特征向量 $f^e(e_{wv})$ 则包含键类型、环结构等信息。模型所考虑的节点特征和边特征^[23]如表 3 和表 4 所示。

表 3 节点特征的原子特性

Table 3 Atomic features used as node features

特征	描述	维度
原子类型	原子类型 (C, Cl, F, O)	4
是否成环	原子是否在成环体系中	1
是否芳香性	原子是否是芳香体系的一部分	1
杂化	$sp, sp^2, sp^3, sp^3d, sp^3d^2$	5
键数目	原子相连的键数目 (0~6)	7
氢原子数目	原子相连的氢原子数目 (0~3)	4

表 4 边特征的化学键特征

Table 4 Bond features used as edge features

特征	描述	维度
键类别	单键、双键、叁键或芳香键	4
共轭	键是否共轭	1
成环	键是否属于环结构	1
立体	无、任意、E、Z、顺式、反式	6

表 1 数据集概况

Table 1 Summary of database

数据集	模型输入: 模型输出	数量
#1	SMILES: T_c (°C)	2508
#2	SMILES + T : H_{eva} (J/mol)	44717
#3	SMILES + T : C_{pg} (J/(mol·°C))	44717
#4	SMILES + T : C_{pl} (J/(mol·°C))	44717

表 2 数据集包含的分子基团

Table 2 Molecular groups of database

链烃	环烃	芳烃
'CH ₃ ', 'CH ₂ ', 'CH', 'C', 'CH ₂ =CH', 'CH=CH', 'CH ₂ =C', 'CH=C', 'C=C', 'CH ₂ =C=CH', 'CH ₂ =C=C', 'CH=C=CH', 'CH=C=C', 'C=C=C', 'CH≡C', 'C≡C', 'CH ₂ Cl', 'CHCl', 'CCl', 'CHCl ₂ ', 'CCl ₂ ', 'CCl ₃ ', 'CH ₂ F', 'CHF', 'CF', 'CHF ₂ ', 'CF ₂ ', 'CF ₃ ', 'CCl ₂ F', 'CHClF', 'CClF', 'CClF ₂ ', '—F except as above', '—Cl except as above'	'CH ₂ (cyclic)', 'CH(cyclic)', 'C(cyclic)', 'CH=CH(cyclic)', 'CH=C(cyclic)', 'C=C(cyclic)', 'C(cyclic)=CH ₂ ', 'C(cyclic)=CH', 'C(cyclic)=C', 'CF ₂ (cyclic)', 'CClF(cyclic)', 'CF(cyclic)', 'CHF(cyclic)', 'CCl ₂ (cyclic)', 'CHCl(cyclic)', 'CCl(cyclic)'	'aC—Cl', 'aC—F', 'aCH', 'aC'

2.2 图神经网络

图神经网络以分子图及其特征向量为输入。GNN 有两个主要阶段：消息传递阶段(message passing phase)和读取阶段(readout phase)。在消息传递阶段中,通常使用图卷积层,构建不同图卷积层实现不同效果。图1展示了图卷积层的基本概念,在一维图神经网络(1-GNN)中,图卷积层的目标是将节点($\odot$ 表示)的信息与其邻居($\ominus$ 表示)和键信息($---$ 表示)相结合。为此,通过消息和更新函数将节点状态向量和边状态向量组合在一起,具体过程如下。

在图卷积层内,一个节点 v 的邻域信息通过式(1)获得:

$$N(v) = \{w | e_{vw} \in E, w \neq v\} \quad (1)$$

即通过边 $e_{vw} \in E$ 判断是否为相邻节点。消息 m_v^l 通过消息函数 M_l 沿着边传递到节点,通过式(2)获得:

$$m_v^l = \sum_{w \in N(v)} M_l[h_w^{l-1}, f^E(e_{vw})] \quad (2)$$

式中, h_w^{l-1} 表示第 $l-1$ 层邻域的隐藏状态向量。第0个隐藏状态向量使用节点的输入特征向量进行初始化,即 $h_w^0 = f^V(v)$ 。消息函数 M_l 取决于邻域在上一层的隐藏状态 h_w^{l-1} 和相应边特征 $f^E(e_{vw})$,对于 $l > 0$ 层,隐藏状态向量的维度是一个超参数。随后,节点 v 的隐藏状态 h_v^{l-1} 通过更新函数 U_l 更新为 h_v^l ,更新函数 U_l 将来自前一层的隐藏状态与包含从邻域接收到的信息相结合,如式(3):

$$h_v^l = U_l(h_v^{l-1}, m_v^l) \quad (3)$$

消息传递和更新在多个图卷积层 $l \in \{1, 2, \dots, L\}$ 中重复,经过 L 次卷积后,节点的隐藏状态 h_v^L 包含半

径为 L 个节点的局部环境信息。

在读取阶段,最后一个卷积层的隐藏节点状态通过池化函数(pooling)组合成一个图表示向量 h_G ,即分子指纹,如式(4):

$$h_G = p(h_1^L, h_2^L, \dots, h_v^L) \quad (4)$$

其中,函数 p 通常选择为平均值、总和或最大值函数。最后,分子指纹向量 h_G 被用于分子性质回归,例如使用多层感知器(MLP):

$$\hat{p} = \text{MLP}(h_G) \quad (5)$$

式中, $\hat{p}$ 为分子性质。上述方法从分子图到属性的所有函数都是显式且可微的,允许使用反向传播进行监督训练。

图1中二维图神经网络(2-GNN)的原理与上述介绍的1-GNN相近,主要区别在于2-GNN中的节点是由两个原子组成的原子对,而1-GNN中的节点为单个原子。因此,2-GNN可以获取基于原子对的更高维度的特征。值得说明的是,高维GNN训练时需包含测试集中所有分子包含的原子对,否则无法预测测试集分子的性质。

3 模型介绍

3.1 模型框架

本研究分别使用PyTorch和RDKit进行深度学习和化学分子信息提取。本研究所构建的GNN模型结合多维图神经网络与递归神经网络。通过高维图神经网络,模型可以提取分子图的更高阶特征。模型使用门控循环单元作为递归神经网络,相比于长短期记忆模型,参数更少且避免了梯度消失问题。如图1所示,在信息传递阶段中使用了1-




图1 模型示意图

Fig.1 Overview of the model

GNN和2-GNN,获得单个原子在分子的局部环境以及原子对在分子的相互作用,所对应的特征均在模型训练过程逐步识别。经过池化后,1-GNN和2-GNN的两个图形表示向量连接成分子指纹,作为深度MLP的输入,预测临界温度。当模型用于预测蒸发焓、气相摩尔热容和液相摩尔热容时,分子指纹与温度信息连接,共同作为深度MLP的输入。

3.2 训练方法

为了防止模型过拟合,将表1中所示的数据集随机分为训练集(70%)、验证集(15%)和测试集(15%),验证集作为训练停止的判断标准,数据集在训练前进行归一化处理。模型采用批次训练的方法,训练过程以均方误差为损失函数。每一次训练后,均测试模型在验证集的表现,如果模型在验证集上的误差连续三次未减少,则学习率将以0.8的因子衰减。如果模型在验证集上的表现连续25次不改进,或者达到最大训练次数(500次),则终止模型训练。模型部分超参数如下:1-GNN和2-GNN的卷积层数目为2;1-GNN和2-GNN输出的分子指纹维度为64;MLP为5层结构;MLP各层神经元数目分别为128/129、64、32、16、1;初始学习率为0.001;批次训练集大小为64。

4 结果讨论与分析

4.1 临界温度预测模型

根据表1中所列数据集#1和第3节所介绍的方法,模型总共训练49次,在第24次训练后,模型在验证集上的性能不再改进。预测模型训练过程的平均绝对误差(MAE)及真实值和预测值对比及分布如图2所示。图2所涉及的训练集、验证集和测试集数据可通过该链接(<https://github.com/NicolasHong/CIESC-GNN-Data>)下载。训练过程中,临界温度预测模型在训练集、验证集和测试集上的平均绝对误差如图2(a)所示。图2(c)展示了临界温度预测模型在训练集、验证集和测试集上预测值与真实值的偏差,分别由蓝色、橙色和绿色所表示,黑色虚线表示预测值和真实值偏差在+20%和-20%的范围。本模型对含有C、F、Cl的烃类物质具有良好的预测性能,仅3.7%和0.7%的测试集数据预测误差大于10%和20%。表5使用均方根误差(RMSE)、平均绝对误差和相关系数(R^2)三个统计指标评估了该模型预测 T_c 的准确性。模型在测试集

上的RMSE为13.6,MAE为9.7, R^2 为0.97,结果优于文献^[30]报道的预测精度,其训练集与测试集的MAE分别为22.5和22.8。由于文献^[30]没有公开全部训练数据集,所以无法将其用于训练本研究所构造的模型。文献^[30]以1432个数据为训练集,本研究使用1756个数据,两个模型所使用的训练集的大小是相近的,结果对比说明本研究所构建的预测模型取得了更好的预测效果。图2(c)也展示了数据库中23个HFO分子的模型预测值与真实值的对比,其 R^2 为0.98。

4.2 蒸发焓、气相摩尔热容和液相摩尔热容预测模型

根据表1中所列数据集#2、#3、#4和第3节所介绍的方法,训练了可以预测烃类分子在不同温度下蒸发焓、气相摩尔热容和液相摩尔热容的模型。与4.1节的临界温度预测模型不同,蒸发焓、气相摩尔热容和液相摩尔热容预测模型在使用1-GNN和2-GNN获得分子指纹后,须将分子指纹与温度信息连接,随后再输入深度MLP模型。

本研究针对这三个性质采用两种训练方法:单个性训练和三个性质同步训练。单个性训练时, H_{eva} 、 C_{pg} 和 C_{pl} 预测模型的训练次数分别为280、500和264。其中, C_{pg} 预测模型训练次数达到上限。但是,模型在经过200次训练后,改进的幅度非常小,如图2(b)所示。所得 H_{eva} 模型在训练集、验证集和测试集的预测值与真实值的比较如图2(d)所示。 H_{eva} 模型与文献^[14,26]模型的比较结果如表6所示,本研究所得模型在训练集、测试集和验证集上的 R^2 均达到0.99以上,高于Yan等^[26]的0.97和Alshehri等^[25]的0.97。此外,MAE和RMSE均小于文献报道结果。但是,如图2(d)所示,部分数据误差较大,其中126个(0.3%)数据点的误差大于20%,45个数据点(0.1%)误差大于30%,45个数据点涉及7个分子。所得 C_{pg} 和 C_{pl} 预测模型在训练集、验证集和测试集的预测值与真实值的比较如图2(e)和图2(f)所示,预测误差超过20%的比例远小于图2(d),图2(e)和图

表5 T_c 预测模型训练集、验证集与测试集的统计结果
Table 5 Statistical results of the training set, validation set and test set by T_c prediction model

指标	训练/验证/测试	训练/测试 ^[30]
均方根误差, RMSE	13.2/14.4/13.6	—
平均绝对误差, MAE	9.1/10.1/9.7	22.5/22.8
决定系数, R^2	0.98/0.98/0.97	—




图2 预测模型训练过程的MAE曲线及 T_c 、 H_{eva} 、 C_{pg} 、 C_{pl} 真实值和预测值对比与分布

Fig.2 MAE curve for prediction model training, and comparison and distribution of the predicted and true T_c , H_{eva} , C_{pg} , C_{pl}

表 6 H_{eva} 预测模型训练集、验证集与测试集的统计结果

Table 6 Statistical results of the training set, validation set and test set by H_{eva} prediction model

指标	训练/验证/测试	训练/测试 ^[26]	训练/测试 ^[14]
均方根误差, RMSE	896.3/958.0/971.8	—	2470.0
平均绝对误差, MAE	342.9/393.3/403.0	2499.0	—
决定系数, R^2	0.99/0.99/0.99	0.97	0.97

表 7 C_{pg} 和 C_{pl} 预测模型训练集、验证集与测试集的统计结果

Table 7 Statistical results of the training set, validation set and test set by C_{pg} and C_{pl} prediction models

指标	训练/验证/测试	
	C_{pg}	C_{pl}
均方根误差, RMSE	2.5/3.3/2.5	3.1/3.6/3.4
平均绝对误差, MAE	1.4/1.7/1.6	1.6/1.9/1.9
决定系数, R^2	1.00/1.00/1.00	1.00/1.00/1.00

2(f)均仅有 1 个点位于范围线之外。表 7 展示了模型的 RMSE、MAE 和 R^2 , 其中 R^2 接近于 1.00, MAE 和 RMSE 分别小于 2 和 4。图 2(d)~(f)也均展示了数据集中 HFO 分子的模型预测值与真实值的对比, 其 R^2 均接近于 1.00。

模型同步训练三个性质时, 为了确保不同性质的数据标签在相同的数量级, 将蒸发焓除以 130, 该值为蒸发焓均值与摩尔热容均值的比值。随后, 对三个性质的数据集进行归一化处理。经过 392 次训练后, 所得 H_{eva} 、 C_{pg} 和 C_{pl} 预测模型在测试集上的 R^2 分别为 0.99、1.00 和 1.00, MAE 分别为 499.2、2.2 和 2.2。使用同步训练方法所得模型的 MAE 均高于单个性训练时所得结果, 说明三个性质所对应的分子指纹特征有一定差异, 同步训练时损失函数为三个性质损失函数的加和, 无法有效调整卷积层的参数以

获得适用于预测三种性质的分子指纹特征。

4.3 新型 HFO 工质热力学性质预测

如上文所述, NIST 和 DIPPR 两个物性数据集中仅包含 23 种 HFO, 与潜在的 HFO 工质存在极大的差距。GDB(generated databases)分子生成库在考虑简单的化合价、化学稳定性和合成可行性规则的情况下, 生成大量包含 C、N、O 和 F 原子的分子。本研究从 GDB 分子生成库中筛选出碳数为 2~10 的物质, 构建 HFO 工质分子数据库, 共包含 43 万个 HFO 分子。将本研究成果模型应用于预测 HFO 的临界温度 T_c , 以及在 $0.9T_c$ 的气相摩尔热容、液相摩尔热容和蒸发焓。表 8 展示了 10 个尚未有公开性质的 HFO 分子的预测值, 完整 43 万个 HFO 分子的预测结果存储于 4.1 节中所提供链接。

5 结 论

本文构造了一个基于多维图神经网络的 ORC 烃类工质的热力学性质预测模型, 包括临界温度、蒸发焓、气相摩尔热容和液相摩尔热容, 其中后三者与温度相关。模型通过 1-GNN 和 2-GNN 分别学习分子的原子和原子对的特征, 获得分子指纹, 并与温度结合, 利用多层感知构建预测不同温度下热力学性质的预测模型。模型以 2508 个 C_2 ~ C_{10} 的链状烃、环烃和芳香烃分子为数据集, 所得模型在预

表 8 10 个 HFO 分子的 T_c 、 H_{eva} 、 C_{pg} 和 C_{pl} 预测结果

Table 8 Prediction results of T_c , H_{eva} , C_{pg} and C_{pl} for 10 HFO molecules

序号	SMILES	$T_c/^\circ\text{C}$	$H_{\text{eva}}@0.9T_c/(\text{J/mol})$	$C_{\text{pg}}@0.9T_c/(\text{J}/(\text{mol}\cdot^\circ\text{C}))$	$C_{\text{pl}}@0.9T_c/(\text{J}/(\text{mol}\cdot^\circ\text{C}))$
1	FC(F)=CC(=C)C(F)(F)F	172.4	15988.5	194.5	227.7
2	FC(F)=C1CCCC1(F)F	218.4	18425.0	239.4	268.0
3	CC1C=CC(F)C1C(F)(F)F	273.2	22472.0	269.5	305.5
4	CC=CCC(F)=CC(C)(C)F	334.6	22170.4	362.0	329.5
5	CC=CC(C)(F)CCC(C)=C	347.9	23476.0	392.1	362.1
6	CCC(CF)(CC(C)=C)C=C	357.8	24531.6	393.1	368.3
7	CC(C)=CCC=CC1CC1F	366.4	27816.5	378.8	346.4
8	FC1CC=CC2CC2(F)C=C1	374.8	25305.4	327.0	312.6
9	FC1=CC(CC1)C=CCC#C	383.7	25063.7	350.4	329.9
10	CC1=CCC2C=CCC2=C1F	396.5	26709.4	330.9	355.6

测临界温度、蒸发焓、气相摩尔热容和液相摩尔热容方面均取得良好效果,部分结果优于文献的预测效果。此外,使用所得模型预测了超43万个HFO分子的热力学性质。后续工作将以ORC工质热力学性质预测模型为基础,开展ORC流程设计与工质同步设计的研究,对寻找高效和环保的新型ORC工质具有重要意义。

符 号 说 明

C_{pg} —— 气相摩尔热容, $\text{J}/(\text{mol} \cdot ^\circ\text{C})$
 C_{pl} —— 液相摩尔热容, $\text{J}/(\text{mol} \cdot ^\circ\text{C})$
 E —— 边集合
 e_{vw} —— 连接节点 v 和 w 的边
 $f^E(e_{vw})$ —— 边 e_{vw} 特征
 $f^V(v)$ —— 节点 v 特征
GWP —— 全球变暖潜数值
 H_{eva} —— 蒸发焓, J/mol
 h_g —— 分子指纹向量
 h_v^l —— 节点 v 的第 l 层隐藏状态
 l —— 卷积层
 M_l —— 第 l 层消息函数
MAE —— 平均绝对误差
 m_v^l —— 节点 v 的第 l 层消息
 $N(v)$ —— 节点 v 的邻居
 $\hat{p}$ —— 分子性质
SMILES —— 简化分子线性输入规范
 T_c —— 临界温度, $^\circ\text{C}$
 U^t —— 更新函数
 V —— 节点集合
 v, w —— 节点

参考文献

- [1] Zhang S, Chen W Y. China's energy transition pathway in a carbon neutral vision[J]. Engineering, 2022, **14**: 64–76.
- [2] Lin Q Y, Zhang X, Wang T, et al. Technical perspective of carbon capture, utilization, and storage[J]. Engineering, 2022, **14**: 27–32.
- [3] Geffroy C, Lilley D, Perez P S, et al. Techno-economic analysis of waste-heat conversion[J]. Joule, 2021, **5**(12): 3080–3096.
- [4] Imran M, Pili R, Usman M, et al. Dynamic modeling and control strategies of organic Rankine cycle systems: methods and challenges[J]. Applied Energy, 2020, **276**: 115537.
- [5] Bellos E, Tzivanidis C. Investigation of a hybrid ORC driven by waste heat and solar energy[J]. Energy Conversion and Management, 2018, **156**: 427–439.
- [6] da Silva Morais P H, Lodi A, Aoki A C, et al. Energy, exergetic and economic analyses of a combined solar-biomass-ORC cooling cogeneration systems for a Brazilian small plant[J]. Renewable Energy, 2020, **157**: 1131–1147.
- [7] Chitgar N, Hemmati A, Sadrzadeh M. A comparative performance analysis, working fluid selection, and machine learning optimization of ORC systems driven by geothermal energy[J]. Energy Conversion and Management, 2023, **286**: 117072.
- [8] Nondy J, Gogoi T K. Exergoeconomic investigation and multi-objective optimization of different ORC configurations for waste heat recovery: a comparative study[J]. Energy Conversion and Management, 2021, **245**: 114593.
- [9] Schwöbel J A H, Preißinger M, Brüggemann D, et al. High-throughput screening of working fluids for the organic Rankine cycle (ORC) based on conductor-like screening model for realistic solvation (COSMO-RS) and thermodynamic process simulations[J]. Industrial & Engineering Chemistry Research, 2017, **56**(3): 788–798.
- [10] Dong X A, Liao Z W, Sun J Y, et al. Simultaneous optimization for organic Rankine cycle design and heat integration[J]. Industrial & Engineering Chemistry Research, 2020, **59**(46): 20455–20471.
- [11] Dong X A, Liao Z W, Sun J Y, et al. Simultaneous optimization of a heat exchanger network and operating conditions of organic Rankine cycle[J]. Industrial & Engineering Chemistry Research, 2020, **59**(25): 11596–11609.
- [12] 王羽鹏, 梁俊伟, 罗向龙, 等. 基于神经网络的有机朗肯循环过程及循环性能计算方法[J]. 化工学报, 2019, **70**(9): 3256–3266.
Wang Y P, Liang J W, Luo X L, et al. Novel prediction method of process and system performance for organic Rankine cycle based on neural network[J]. CIESC Journal, 2019, **70**(9): 3256–3266.
- [13] 李子航, 王占博, 苗政, 等. 亚临界有机朗肯循环系统工质筛选及热经济性分析[J]. 化工学报, 2021, **72**(9): 4487–4495.
Li Z H, Wang Z B, Miao Z, et al. Working fluid selection and thermo-economic analysis of sub-critical organic Rankine cycle[J]. CIESC Journal, 2021, **72**(9): 4487–4495.
- [14] Fouad W A, Vega L F. Next generation of low global warming potential refrigerants: thermodynamic properties molecular modeling[J]. AIChE Journal, 2018, **64**(1): 250–262.
- [15] Nair V. HFO refrigerants: a review of present status and future prospects[J]. International Journal of Refrigeration, 2021, **122**: 156–170.
- [16] 龚正. 分子动力学模拟预测工业流体的热力学性质的方法研究[D]. 上海: 上海交通大学, 2019.
Gong Z. Study on the method of molecular dynamics simulation to predict the thermodynamic properties of industrial fluids[D]. Shanghai: Shanghai Jiao Tong University, 2019.
- [17] Xu Y H, Huang X, Li C P, et al. Predicting structure-dependent properties directly from the three dimensional molecular images via convolutional neural networks[J]. AIChE Journal, 2022, **68**(8): e17721.
- [18] Walters W P, Barzilay R. Applications of deep learning in molecule generation and molecular property prediction[J]. Accounts of Chemical Research, 2021, **54**(2): 263–270.
- [19] Zhang J, Wang Q, Su Y, et al. An accurate and interpretable deep learning model for environmental properties prediction using hybrid molecular representations[J]. AIChE Journal, 2022, **68**(6): e17634.
- [20] Altintas C, Altundal O F, Keskin S, et al. Machine learning meets with metal organic frameworks for gas storage and separation[J]. Journal of Chemical Information and Modeling, 2021, **61**(5): 2131–2146.
- [21] Moghadam P Z, Rogge S M J, Li A, et al. Structure-mechanical

- stability relations of metal-organic frameworks *via* machine learning[J]. Matter, 2019, **1**(1): 219–234.
- [22] Wang S H, Cheng M, Luo L, et al. High-throughput screening of metal-organic frameworks for hydrogen purification[J]. Chemical Engineering Journal, 2023, **451**: 138436.
- [23] Schweidtmann A M, Rittig J G, König A, et al. Graph neural networks for prediction of fuel ignition quality[J]. Energy & Fuels, 2020, **34**(9): 11395–11407.
- [24] Liu R C, Liu R Z, Liu Y F, et al. Design of fuel molecules based on variational autoencoder[J]. Fuel, 2022, **316**: 123426.
- [25] Alshehri A S, Tula A K, You F Q, et al. Next generation pure component property estimation models: with and without machine learning techniques[J]. AIChE Journal, 2022, **68**(6): e17469.
- [26] Yan X, Lan T, Jia Q Z, et al. A norm indexes-based QSPR model for predicting the standard vaporization enthalpy and formation enthalpy of organic compounds[J]. Fluid Phase Equilibria, 2020, **507**: 112437.
- [27] Aouichaoui A R N, Fan F, Abildskov J, et al. Application of interpretable group-embedded graph neural networks for pure compound properties[J]. Computers & Chemical Engineering, 2023, **176**: 108291.
- [28] Wang Y Y, Wang J R, Cao Z L, et al. Molecular contrastive learning of representations *via* graph neural networks[J]. Nature Machine Intelligence, 2022, **4**(3): 279–287.
- [29] Morris C, Ritzert M, Fey M, et al. Weisfeiler and leman go neural: higher-order graph neural networks[J]. Proceedings of the AAAI Conference on Artificial Intelligence, 2019, **33**(1): 4602–4609.
- [30] Su Y, Wang Z H, Jin S M, et al. An architecture of deep learning in QSPR modeling for the prediction of critical properties using molecular signatures[J]. AIChE Journal, 2019, **65**(9): e16678.