

基于人工神经网络的工质基础物性预测

林美金¹, 董 轩¹, 洪小东^{1,2}, 廖祖维¹, 孙婧元¹, 杨 遥¹, 王靖岱¹, 阳永荣¹

(1. 浙江大学化学工程与生物工程学院, 杭州 310030; 2. 浙江大学杭州国际科创中心)

摘 要: 烃类及卤代烃是制冷及余热发电等热力学循环系统潜在的理想工质,但其数量繁多且多数物性参数未知,建立准确的物性预测模型对新型工质的开发至关重要。从多个公开数据库中收集了2500多种烃类及卤代烃分子(含C, H, F, Cl)的基础物性参数,包括正常沸点(T_b)、临界温度(T_c)、临界压力(p_c)、偏心因子(ω),构建了一个工质物性数据库;进一步,通过改进基团贡献-人工神经网络(GC-ANN)的方法,模型的输入参数除基团频率外,还加入相对分子质量、 T_b 、约化维纳指数,建立了预测烃类及卤代烃分子 T_b , T_c , p_c , ω 的神经网络模型,所开发模型的预测误差小于传统的 GC-ANN 的误差。

关键词: 新型工质 物性预测 基团贡献法 BP神经网络

制冷及余热发电等热力学循环系统的传统工质易引起臭氧层空洞及温室效应,开发高效、环保的新型工质逐渐成为研究热点。在新型有机工质的开发过程中,临界温度(T_c)、临界压力(p_c)、临界体积(V_c)、偏心因子(ω)、正常沸点(T_b)等基础物性是判断工质性能的基础。由于许多物质的临界参数需在高温下测定,测量难度较高,因而目前已经测得临界参数的物质种类较少^[1];此外, ω 与物质分子结构的复杂程度和极性相关,其估算过程非常复杂。许多烃类及卤代烃分子是潜在的环境友好型制冷剂和余热发电工质,但目前对含氟/氯原子有机化合物的临界参数、偏心因子等缺乏准确的预测方法^[2]。如何高效、准确地预测烃类及卤代烃的基础物性,是新型制冷、余热发电工质开发面临的关键难题。

常见的物性估算方法主要包括经验式法、状态方程估算法、定量构效关系法(QSPR)^[3]。经验式法利用一些较为常见且易于测量的参数,如沸点、密度等,建立其他物性的关联式,从而得到物质的临界参数。例如, Guldberg 提出了 $T_c = 1.5T_b$ 的经验式,来估算物质临界温度^[4];周传光等^[5]通过有机化合物临界参数的试验值与其相对分子质量、沸点、密度等基本参数的关系,建立了一组推算 V_c , T_c , p_c 的关联式;Vejahati 等^[6]提出了一种简单的指数模型,利用烷烃的 T_b 和相对分子质量估算其临界参数,该指数模型被用于估算30种化合物(包括 $C_2 \sim C_{30}$ 的烷烃)的 T_c , p_c , V_c , 结果平均绝对误差分别为 0.49%, 1.16%,

0.97%。状态方程估算法通过对工质温度、压力、体积数据的拟合,来获得其状态方程中相应参数,但状态方程涉及的参数往往缺乏试验数据支撑^[3]。目前,基于 Rackett 方程、Spencer 方程的估算式均较复杂,计算精度不高,且不适合多基团化合物,因而较少使用。QSPR 法则是根据物质分子结构-物化性质间的构效关系,对工质物性进行建模和预测,代表性的 QSPR 法有基团贡献法、基团贡献-人工神经网络集成法等。基团贡献法(GCM)是 QSPR 中最常用的一种方法,它基于两个基本假设:①基团的贡献值是一个常数,与基团所在的物质种类无关;②分子的性质具有加和性。GCM 的原理简单,适用范围广,利用基团贡献法可以计算工质的许多基础物性,如熔点、蒸发焓、比热容及临界参数(T_c , p_c , V_c)等^[7-11]。然而,这些方法只考虑了一阶基团贡献,无法区分同分异构体,预测精度也不高。基于此, Lymeriadis 等^[12]采用定位分步法等新方法对 GCM 方法进行了改进,但改进方法均存在不同问题并导致计算变得更加复杂。基团贡献-人工神经网络法(GC-ANN)结合了基团贡献法和神经网络的优点,将基团和部分结构参数作为神经网络的输入变量,利用人

收稿日期:2023-09-18。

作者简介:林美金,硕士研究生,主要研究方向为新型工质性质预测及有机朗肯循环优化。

通讯联系人:洪小东, E-mail: hongxiaodong@zju.edu.cn。

基金项目:国家自然科学基金项目(U22A20415);浙江省尖兵领雁计划项目(2022C01SA442617)。

工神经网络擅长处理复杂数据关系的优点,简化了计算过程,提高了预测精度。Lazzús 等^[13]利用 GC-ANN 方法预测了 72 种离子液体的密度-温度-压力(ρ - T - p)数据,发现预测结果与试验数据一致性较高,说明 GC-ANN 方法预测精度较高,是估算离子液体密度的一种优选方法。Ghragheizi 等^[14]采用 GC-ANN 方法对由 81 种基团构成的 1 700 种化合物的 p_c , T_c , V_c , ω 进行了预测,发现预测结果的精确度较高,其绝对平均误差分别为 1.1%, 0.9%, 1.4%, 3.7%。Mondejar 等^[2]对比了采用 GCM 和 GC-ANN 预测含氯/氟卤代烯烃的临界参数和 ω ,结果表明 GC-ANN 方法的预测精度更高。Wang Qiang 等^[15]提出了利用基团定位法区分同分异构体的 GC-ANN 模型,用于预测物质的正常沸点、蒸发焓和临界参数,结果表明该模型的预测精度较高。


目前,虽然国内外对 GC-ANN 方法估算物质物性的研究已相对成熟,但利用该方法预测含氟/氯有机化合物物性的报道^[16]仍然很少。因此,本研究以 SMILES(Simplified Molecular Input Line

Entry System)的形式描述工质分子,构建一个含 C, H, F, Cl 原子的低碳烃工质分子的物性(T_b , T_c , p_c , ω)数据库;进而,基于 GC-ANN 方法,以分子基团、相对分子质量、正常沸点、约化维纳指数作为模型输入变量,以工质物性(T_b , T_c , p_c , ω)作为模型输出变量,建立工质物性预测模型。其中,分子基团变量除简单的一阶基团^[7-11]外,同时考虑由一阶基团组合构成的二阶基团,从而可以更高效、准确地预测烃类及卤代烃的基础物性,为新型有机工质的开发提供理论指导。

1 方法

1.1 构建工质分子库

首先,从公开数据库 NIST(National Institute of Standards and Technology)^[17]和 DIPPR(Design Institute for Physical Properties)^[18]中搜集了包含 C, H, F, Cl 元素的所有低碳烃的物性数据(包括 T_b , T_c , p_c , ω),构建了包含 2 504 种物质分子的工质分子物性数据库,工质的种类如图 1 所示。



1.2 确定分子描述符

本研究以 SMILES 作为分子描述符,并拆解工质分子物性数据库中的各分子,得到一阶基团和二阶基团,见表 1。其中,一阶基团为构成分子的简单基团,旨在通过一阶基团的组合形成各种有机化合物,并区分链烃、环烃、芳香烃,一阶基团

的识别标准遵循文献^[19]方法;二阶基团为一阶基团的组合,旨在描述无法由一阶基团组充分描述的分子片段。在本研究中,二阶基团主要包括碳环[如表 1 中 C_3 (环)表示含 3 个碳的环烷基]、两个双键组合、以及双键(或三键)与卤原子组合。

表 1 工质库内的分子基团

一阶基团			二阶基团
链烃	环烃	芳烃	
CH ₃ ,CH ₂ ,CH,C,CH ₂ =CH,CH=CH,CH ₂ =C,CH=CH,C=C,CH ₂ =C=CH,CH ₂ =C=C,CH=C=CH,CH=C=C,C=C=C,CH≡C,C≡C,CH ₂ Cl,CHCl,CCl,CHCl ₂ ,CCl ₂ ,CCl ₃ ,CH ₂ F,CHF,CF,CHF ₂ ,CF ₂ ,CF ₃ ,CCl ₂ F,CHClF,CClF,CClF ₂ ,上述基团之外的 F、Cl 原子	CH ₂ (环),CH(环),C(环),CH=CH(环),CH=C(环),C=C(环),C(环)=CH ₂ ,C(环)=CH,C(环)=C,C(环)F ₂ ,C(环)ClF,C(环)F,C(环)HF,C(环)Cl ₂ ,C(环)HCl,C(环)Cl	芳 C—Cl,芳 C—F,芳 C—H,芳 C	C ₃ (环),C ₄ (环),C ₅ (环),C ₆ (环),C ₇ (环),C ₈ (环),C ₉ (环),C ₁₀ (环),C=C—C=C,C=CF ₂ ,C=CF,C=CCl ₂ ,C=CCl,C=CClF,C=CF,C=CCl

除分子基团外,相对分子质量^[5-6]、正常沸点^[5-8]也常被用于临界参数的计算,因此本研究也将这两个参数作为 GC-ANN 模型的输入变量。此外,分子基团只能描述分子二维结构,无法对分子内原子的键合方式、几何结构定量描述,为了提高模型的预测精度,特引入约化维纳指数(W)作为 GC-ANN 模型的输入变量。W 是一个分子拓扑指数,用于描述分子结构,反映了分子的紧凑程度,W 数值越小,分子结构越紧凑,其计算式如式(1)所示。

$$W = \frac{\sum_{i=1}^n \sum_{j=1}^n D_{ij}}{2n^2}$$

(1)

式中: D_{ij} 为距离矩阵 D 第 i 行第 j 列对应元素; n 为距离矩阵 D 的行数。

以 2,3-二甲基丁烷 $[(CH_3)_2CHCH(CH_3)_2]$ 的 W 的求取过程为例,首先对其分子中的碳原子进行编号,主链优先,编号通常从 1 开始依次递增,可以按碳原子在分子中的顺序来分配;其次获得距离矩阵,再通过式(1)计算得到物质分子的 W ,如图 2 所示。




图 2 2,3-二甲基丁烷的 W 的求取过程

因此,所建模型的输入变量包括分子基团出现频率、相对分子质量、 T_b 、 W 。

1.3 数据预处理

在获取分子描述符的数据和基团出现频率后,需要对数据进行归一化处理,避免因原始数

据特征间数值差距过大引起梯度震荡,影响正常运算。将不同数据均归一化到 $[-1,1]$ 区间,归一化方法如式(2)所示。

$$X = \frac{2x_i - \max(x) - \min(x)}{\max(x) - \min(x)}$$

(2)

式中: x_i 为归一化前的输入参数(包括 T_b 、相对分子质量、 W 、基团频率); X 为归一化后的输入参数。

1.4 人工神经网络模型构建

BP(Back propagation)神经网络是一种按照误差逆向传播算法训练的多层前馈神经网络,是当前应用最广泛的人工神经网络。设计 BP 神经网络模型,首先要确定合适的网络结构,包括输入层和输出层的神经元数、隐藏层的数量和每层节点数,其次还需要确定激活函数类型。隐藏层神经元数量过多,可能导致模型过拟合,而神经元数目过少则可能导致模型欠拟合。目前对于 BP 神经网络隐藏层数及隐藏节点数的确定大都依靠经验或者试错。式(3)~式(5)为优选隐藏层节点数的经验式。

$$m = \sqrt{n+l} + \alpha$$

(3)

$$m = \log_2 n$$

(4)

$$m = \sqrt{n \times l}$$

(5)

式中: m 为隐藏层节点数; n 为输入层节点数; l 为输出层节点数; α 为 1~10 之间的常数。

1.5 评估指标的选择

选用相关系数(R)、平对绝对偏差(AARD)、绝对相对偏差(ARD)作为模型预测精度的评价指标,其计算式见式(6)~式(8)。其中, R 用于表征真实值与模型预测值间的线性相关程度, R 越接近 1,二者线性相关度越高。AARD 和 ARD 指标为绝对值,不会出现预测结果偏差正负抵消的情况,能够更好地反映模型的预测精度。

$$R(x, x_{est}) = \frac{\text{Cov}(x, x_{est})}{\sqrt{\text{Var}[x]\text{Var}[x_{est}]}}$$

(6)

$$\text{AARD} = \frac{1}{N} \sum_{i=1}^N 100 \left| \frac{x_{\text{est}} - x}{x} \right| \tag{7}$$

$$\text{ARD} = \left| \frac{x_{\text{est}} - x}{x} \right| \tag{8}$$

式中： x_{est} 为模型预测值； x 为真实值； $\text{Cov}(x, x_{\text{est}})$ 为预测值与真实值的协方差； $\text{Var}[x]$ 和 $\text{Var}[x_{\text{est}}]$ 分别为真实值和预测值的方差。

2 结果与讨论

2.1 模型的建立与评估

针对工质 T_b, T_c, p_c, ω 性质,分别构建以基团频率为输入变量的 BP 神经网络模型和以基团频率结合一个或多个辅助描述符(相对分子质量、 T_b, W)的 BP 神经网络模型。由式(3)~式(5)确定模型隐藏层数为 2,并采用试错法确定了最优的隐藏层节点数。基于此建立 BP 神经网络模型,其结构如图 3 所示,其结构参数见表 2。为提升模型的泛化能力,将 2 504 组物性数据分为训练集、验证集和测试集,其数据分配比例为 70 : 15 : 15。为了解决传统梯度下降法计算收敛慢或易陷入局部

最小值等问题,采用量化共轭梯度法(SCG)对模型进行训练,获得具有最小均方误差(MSE)的模型参数,MSE 的计算式见式(9)。

$$\text{MSE} = \frac{1}{N} \sum_{i=1}^N (x_{\text{est}} - x)^2 \tag{9}$$




图 3 BP 神经网络模型的基本结构

表 2 BP 神经网络模型的结构参数

模型输入参数	模型输出参数	输入层数据维度	输出层数据维度	第一隐藏层神经元数	第二隐藏层神经元数	激活函数	训练函数
基团频率+相对分子质量	T_b	$2\ 504 \times 76$	$2\ 504 \times 1$	4	2	Tansig	SCG
基团频率+ T_b	T_c	$2\ 504 \times 76$	$2\ 504 \times 1$	9	3	Tansig	SCG
基团频率+ T_b +相对分子质量	p_c	$2\ 504 \times 77$	$2\ 504 \times 1$	12	6	Tansig	SCG
基团频率+ T_b + T_c + T_p	ω	$2\ 504 \times 78$	$2\ 504 \times 1$	5	2	Tansig	SCG

2.2 T_b 的神经网络模型预测结果

一般而言,物质的相对分子质量越大则沸点越高。考察模型输入变量分别为基团频率(模型 A1)、基团频率+W(模型 A2)、基团频率+相对分子质量(模型 A3)时模型预测工质 T_b 的效果。3 种模型预测 T_b 的精确度如表 3 所示。由表 3 可知,模型 A1, A2, A3 预测 T_b 的 AARD 分别为 1.680%, 1.592%, 1.723%。可见模型输入变量为

基团频率+相对分子质量时的模型 A2 的 AARD 最小,预测精确度最高。

图 4 为模型 A2 在训练集、验证集、测试集和全部数据集的预测结果。由图 4 可知,无论是训练集、验证集或测试集数据,预测值与真实值的一致性均较好,拟合曲线的相关系数 R 均大于 0.98,说明数据拟合效果好、泛化能力强。分析认为,将相对分子质量作为模型输入变量引入,对提高 T_b 的预测精度起正向作用,这是因为相对分子质量反映分子的整体属性,与分子的原子组合有关,反映了分子中所有原子的组成信息;同时,通过引入相对分子质量,模型可以更好地泛化到不同种类的分子,不再局限于已定义的基团特性,有助于拓展处理不同类型的分子。

表 3 不同模型预测 T_b 的精确度比较

项 目	模型 A1	模型 A2	模型 A3
模型输入 频率	基团频率	基团频率+相 对分子质量	基团频率+W
AARD, %	1.680	1.592	1.723




图4 模型 A2 的训练结果

2.3 T_c 的神经网络模型训练结果

针对工质的 T_c , 分别构建了输入变量为基团频率(模型 B1)、基团频率+W(模型 B2)、基团频率+相对分子质量(模型 B3)、基团频率+ T_b (模型 B4)的 4 个神经网络模型。4 种模型预测 T_c 的精确度如表 4 所示。由表 4 可知, 模型 B1, B2, B3, B4 训练结果的 AARD 分别为 1.947%, 1.751%, 1.865%, 1.284%, 可见模型输入变量为基团频率+ T_b 的神经网络模型(模型 B4)的 AARD 最小。

表4 不同模型预测 T_c 的精确度比较

项 目	模型 B1	模型 B2	模型 B3	模型 B4
模型输入参数	基团频率	基团频率+W	基团频率+ 相对分子 质量	基团频率+ T_b
AARD, %	1.947	1.751	1.865	1.284

模型 B4 在训练集、验证集、测试集和全部数据集的预测结果如图 5 所示。由图 5 可以看出, 模型 B4 在所有数据集中预测 T_c 拟合曲线的相关系数 R 都在 0.99 以上, 表明其拟合效果好, 模型泛化能力强, 说明将基团频率+ T_b 作为模型输入参数时的预测精度最高, 这可能是因为 T_b 和 T_c 都是描述物质相变性质的参数, 其相互间存在某种

程度上的相关性, 将 T_b 作为输入参数预测 T_c , 可以更好地捕捉二者之间的关联; 而且, T_b 提供了有关分子热稳定性的信息, 在预测 T_c 时可以帮助模型更好地理解分子的热力学特性, 从而提高预测精度。此外, 由于物质临界参数(T_c 等)与其分子结构有关, 与相对分子质量相比, W 更好地反映了分子间距与分子结构的关系, 将 W 作为模型输入变量时(模型 B2), 模型 B2 的预测精度比仅使用基团频率(模型 B1)或使用基团频率+相对分子质量(模型 B3)作为输入变量的模型更高。

2.4 p_c 的神经网络预测结果

p_c 是较难预测的基础物性之一, 分别以基团频率(模型 C1)、基团频率+W(模型 C2)、基团频率+相对分子质量(模型 C3)、基团频率+ T_b (模型 C4)、基团频率+ T_b +相对分子质量(模型 C5)作为输入变量构建 5 种神经网络模型, 训练后 5 种神经网络模型预测结果的 AARD 如表 5 所示。由表 5 可知, 当输入变量为基团频率+ T_b +相对分子质量时, 模型 C5 的预测误差 AARD 最小, 预测精度最高。

模型 C5 在训练集、验证集、测试集和全部数据集的训练结果如图 6 所示。从图 6 可以看到, 模型预测 p_c 的精度比预测 T_b 和 T_c 时下降, 原因在于




图 5 模型 B4 的训练结果

表 5 不同模型预测 p_c 精度比较

项 目	模型 C1	模型 C2	模型 C3	模型 C4	模型 C5
模型输入参数	基团频率	基团频率+W	基团频率+相对分子质量	基团频率+ T_b	基团频率+ T_b +相对分子质量
AARD, %	4.680 0	4.602 1	5.507 0	4.657 7	4.159 9




图 6 模型 C5 的训练结果

影响 p_c 的分子属性更多,包括分子大小、形状、极性、分子间相互作用等,而 T_b 和 T_c 受到的影响因素通常更少。总体而言,预测 p_c 时模型拟合曲线的相关系数 R 大于 0.95,仍满足预测精度要求。加入变量 T_b 和相对分子质量,可以更好地理解分子的结构和大小,对提高 p_c 的预测精度有利。此外,当输入变量为基团频率+W 时,模型 C2 的预测精度比其余 3 种模型更高,原因可能是 W 通过距离矩阵更好地反映了碳原子间距的大小,从而使模型更精确地考虑了碳原子间的相互作用,反映了物质微观结构对 p_c 的影响,因而提高了模型对 T_c 和 p_c 的预测精度。

2.5 ω 的神经网络预测结果

由于 ω 与分子结构的复杂程度和分子极性有较弱的关联,很难通过单一理论模型来准确描述,需要大量的试验数据来验证模型的有效性。然而,有些物质的试验数据非常有限或不存在,导致难以建立准确的预测模型。在预测 ω 时,若仅将基团频率

作为输入变量(模型 D1),模型预测的 AARD 达 24.39%,预测精度远远不能满足要求。原因在于模型 D1 没有考虑分子内原子间相互作用和化学键的相互作用,导致其预测结果较差。因此,结合多个 ω 计算公式,包括 Lee-kesler 方程、Riedel 方程、Domez-Rhodos 方程、Nath 方程,构建了以 p_c 、 T_b 、 T_c 和基团频率作为输入变量的预测模型(模型 D2),大幅提高预测的准确性,其预测 AARD 降至 1.498%,其在训练集、验证集、测试集和全部数据集的预测结果如图 7 所示。由图 7 可知,模型 D2 在训练集、验证集、测试集预测结果的拟合相关系数 R 均大于 0.988,说明其预测精度很高。这是因为提高 ω 预测精度的关键在于引入表征分子结构的参数,模型 D2 添加 T_b 、 T_c 、 p_c 作为输入变量, T_b 、 T_c 、 p_c 均与分子结构有关,从而弥补了表征 ω 拓扑指数较少的缺陷。目前,很多物质分子的拓扑结构、拓扑指数难以求解,但若能得到该物质的 T_b 、 T_c 、 p_c 等数据,则可以利用模型 D2 更准确地预测其 ω 。




图 7 模型 D2 的训练结果

2.6 分析与对比

不同方法对含 C, H, F, Cl 原子有机化合物 T_b 、 T_c 、 p_c 、 ω 的预测结果对比见表 6。由表 6 可知,本研究所建模型的预测精度较高,尤其是对

T_b 、 T_c 、 ω 的预测,本研究所建模型的预测 AARD 远小于文献报道结果,原因在于本研究在建立模型时,引入了 T_b 、 T_c 、 p_c 作为输入参数,弥补了缺少表征 ω 拓扑指数的缺陷;同时在基团划分时引

入了二阶基团和顺反异构,且引入 T_b 、相对分子质量作为模型输入变量。

表 6 不同方法预测结果的 AARD 比较

来源	AARD, %			
	T_b	T_c	p_c	ω
本研究	1.596	1.284	4.156	1.498
[19]	6.19	8.16	5.82	
[7]		7.37	7.00	
[20]	2.8			
[21]		2.65	4.65	
[22]		3.70	3.10	
[2]	1.88	2.37	3.10	7.00
[23]				2.84
[9]				4.2

3 结 论

采集了来自 NIST 和 DIPPR 数据库的 2 504 种含 C, H, F, Cl 原子的有机分子物性参数,包括 T_b , T_c , p_c , ω 等多种物性数据。基于基团贡献-人工神经网络的方法,建立了预测含 C, H, F, Cl 原子有机化合物的 T_b , T_c , p_c , ω 的 BP 神经网络模型,并进行了优化。

结果表明, T_b , T_c , p_c , ω 预测模型的 AARD 分别为 1.284%, 4.159%, 1.592%, 1.498%。其中,预测 T_b , p_c , ω 的模型具有较高的预测精度,远高于文献报道的经典模型。尤其是对工质 ω 的预测模型,引入了 T_b , T_c , p_c 作为输入变量,弥补了缺少表征 ω 拓扑指数的缺陷,使得模型预测精度大幅提高。

对比不同输入变量的神经网络模型的预测结果,发现引入相对分子质量、 T_b 及 W 作为输入变量,对提高模型预测精度有着积极作用。此外,随着工质数据的不断补充,可以针对特定类型的工质搭建不同的神经网络模型,从而得到更优异的预测结果。

参 考 文 献

- [1] He M, Wang C, Chen J, et al. Prediction of the critical properties of mixtures based on group contribution theory [J]. Journal of Molecular Liquids, 2018, 271: 313-318
- [2] Mondejar M E, Cignitti S, Abildskov J, et al. Prediction of properties of new halogenated olefins using two group contribution approaches[J]. Fluid Phase Equilibria, 2017, 433: 79-96
- [3] 任嘉辉,刘豫,刘朝,等.基于分子指纹和拓扑指数的工质临

- 界温度理论预测[J]. 化工学报, 2022, 73(4): 1493-1500
- [4] 王小艳,司继林,张达,等.纯物质临界参数估算方法的研究进展[J]. 化工进展, 2012, 31(9): 1871-1877
- [5] 周传光,杨福胜,胡仰栋,等.由化合物的沸点及比重推算临界参数[J]. 计算机与应用化学, 1994(2): 123-126
- [6] Vejahati F, Nikoo M B, Mokhtab S, et al. Simple correlation estimates critical properties of alkanes[J]. Petroleum Science and Technology, 2007, 25(9): 1115-1123
- [7] Joback K G, Reid R C. Estimation of pure-component properties from group-contributions [J]. Chemical Engineering Communications, 1987, 57(1/2/3/4/5/6): 233-243
- [8] Ambrose D. Correlation and estimation of vapor-liquid critical properties: Critical temperatures of organic compounds [R]. Npl Rep Chem 92, Nat Phys Lob, UK, 1978
- [9] Constantinou L, Gani R. New group contribution method for estimating properties of pure compounds [J]. AIChE Journal, 1994, 40(10): 1697-1710
- [10] Jorge M M, Eladio P F. Estimation of pure compound properties using group-interaction contributions[J]. AIChE Journal, 1999, 45(3): 615-621
- [11] 梁英华,马沛生. A new group-contribution method for critical properties[J]. Chinese Journal of Chemical Engineering, 2000 (1): 78-83
- [12] Lymeriadis A, Adjiman C S, Jackson G, et al. A generalisation of the SAFT- γ group contribution method for groups comprising multiple spherical segments[J]. Fluid Phase Equilibria, 2008, 274(1/2): 85-104
- [13] Lazzús J. ρ - T - P prediction for ionic liquids using neural networks[J]. Journal of The Taiwan Institute of Chemical Engineers, 2009, 40: 213-232
- [14] Gharagheizi F, Eslamimanesh A, Mohammadi A H. Determination of critical properties and acentric factors of pure compounds using the artificial neural network group contribution algorithm[J]. Journal of Chemical and Engineering Data: the ACS Journal for Data, 2011, 56(5): 2460-2476
- [15] Wang Qiang, Ma Peisheng, Jia Qingzhu, et al. Position group contribution method for the prediction of critical temperatures of organic compounds[J]. Journal of Chemical and Engineering Data, 2008, 53(5): 1103-1109
- [16] Lukawski M Z, Dipippo R, Tester J W. Molecular property methods for assessing efficiency of organic Rankine cycles [J]. Energy, 2018, 142: 108-120
- [17] Friend D, Huber M. Thermophysical property standard reference data from NIST [J]. International Journal of Thermophysics, 1994, 15: 1279-1288
- [18] Wilding W V, Rowley R L, Oscarson J L. DIPPR® Project 801 evaluated process design data [J]. Fluid Phase Equilibria, 1998, 150/151: 413-420
- [19] Marrero J, Gani R. Group-contribution based estimation of pure component properties[J]. Fluid Phase Equilibria, 2001, 183/184
- [20] Sukumar D, Asha C. Unified artificial neural network-group

- contribution method for predictions of normal boiling point and critical temperature of refrigerants and related compounds [J]. *International Journal of Refrigeration*, 2022, 140: 112-124
- [21] Sobati M A, Aboali D. Molecular based models for estimation of critical properties of pure refrigerants; Quantitative structure property relationship (QSPR) approach[J]. *Thermochimica Acta*, 2015, 602: 53-62
- [22] Lai A N. Prediction of the critical properties; A simple accurate strategy applied to environmentally friendly substances HFOs [J]. *Fluid Phase Equilibria*, 2020, 506: 112377
- [23] Mauro B, Luigi M. Comparison between multi-linear- and radial-basis-function-neural-network-based QSPR models for the prediction of the critical temperature, critical pressure and acentric factor of organic compounds[J]. *Molecules (Basel, Switzerland)*, 2018, 23(6): 1379-1379

PREDICTION OF PHYSICAL PROPERTIES OF WORKING FLUID BASED ON ARTIFICIAL NEURAL NETWORK

Lin Meijin¹, Dong Xuan¹, Hong Xiaodong^{1,2},


Liao Zuwei¹, Sun Jingyuan¹, Yang Yao¹, Wang Jingdai¹, Yang Yongrong¹

(1. College of Chemical Engineering and Bioengineering, Zhejiang University, Hangzhou 310030;

2. ZJU-Hangzhou Global Scientific and Technological Innovation Center)

Abstract: Traditional working fluids in thermodynamic cycles, such as refrigeration and waste heat power generation, have been associated with issues such as ozone layer depletion and global warming. The development of efficient and environmentally friendly novel working fluids has become a research focus. Hydrocarbons and halogenated hydrocarbons are ideal candidates, but their large number and many unknown thermophysical properties make it crucial to establish accurate models for predicting these properties in order to screen new working fluids effectively. In this study, the basic thermophysical parameters of more than 2 500 hydrocarbons and halogenated hydrocarbons containing C, H, F, and Cl atoms were collected from various public databases, including normal boiling point (T_b), critical temperature (T_c), critical pressure (p_c) and acentric factor (ω), and furtherly, by improving the method of group contribution-artificial neural network (GC-ANN), a neural network model for predicting T_b , T_c , p_c and ω of hydrocarbons and halogenated hydrocarbons containing C, H, F, and Cl atoms was established by adding relative molecular mass, T_b and approximate wiener index to the input parameters of the model. The prediction errors of the models developed in this study were smaller than those of the traditional GC-ANN.

Key Words: new working fluid; property prediction; group contribution method; BP neural network



到 2029 年全球废物转化能源市场 将达到 446 亿美元

印度《财富商业洞察》(Fortune Business Insights)报告称,全球废物转化能源(WTE)市场规模预计将从 2022 年的 332.8 亿美元增长到 2029 年的 446.2 亿美元,预计该市

场将以 4.3% 的年均复合增长率扩张。

该报告称:WTE 市场是由废物产生量的增加、环境问题、政府激励措施以及将废物转化为清洁能源的技术进步等因素驱动的。由于经济活动的增加和垃圾产生量的增加,亚太地区将成为主导市场。此外,许多政府鼓励建设垃圾焚烧发电设施,这将使亚太地区在该期间拥有最大的垃圾焚烧发电市场份额。欧洲市场是仅次于亚太地区的第二大市场。这是因为欧洲有几个 WTE 设施和工厂,能源产量不断增加,城市固体垃圾中有价值的材料回收量也在增加。

[汤玮健摘译自 Biofuels Digest, 2023-09-24]