


自编码器, AutoEncoder, AE

• 自编码是什么？

H You
自编码器的自是什么意思? autoencoder

ChatGPT
"自编码器" (Autoencoder) 这个术语中的"自"是指模型尝试学习对输入数据进行自我编码或表示。它是一种无监督学习的神经网络模型，其中网络的目标是将输入数据经过编码和解码过程后尽可能地还原。自编码器由两个主要部分组成：编码器 (Encoder) 和解码器 (Decoder)。

- **编码器 (Encoder)**：编码器负责将输入数据转换为潜在表示或编码。这个编码通常具有较低的维度，因此可以捕捉输入数据的关键特征。
- **解码器 (Decoder)**：解码器接受编码后的表示，并尝试将其还原为原始输入数据。通过这个过程，自编码器试图学习如何表示和还原输入数据，从而学到数据的有效特征。



$$\text{loss} = \|x - \hat{x}\|^2 = \|x - d(z)\|^2 = \|x - d(e(x))\|^2$$

自编码器示意图解析：

已知 x ，通过训练（最小化loss）获得函数 e 和 d ，分别为编码器和解码器。编码器（函数 e ）把 x 编码为 z ，解码器（函数 d ）把 z 解码为 $\hat{x}$ 。

缺点：“一一对应！” 假设训练结束后 $\text{loss} = 0$ ，那么给定 x_1 编码后得到的也是 x_1 。如果给定 $(1+1e-9)x_1$ 呢？获得的解可能高度偏离 x_1 ，上述loss的定义方式必然导致训练过程只考虑给定 x 的编码和解码，外推差。

变分自编码器, Variational AE, VAE

• 变分是什么？

 You
变分自编码器的变分是什么

 ChatGPT
在变分自编码器 (Variational Autoencoder, VAE) 中, "变分" (Variational) 一词源自变分推断 (Variational Inference) 的概念。变分推断是一种用于近似贝叶斯推断的方法, 其核心思想是通过在某个参数化的分布族中寻找一个近似分布, 使其在某个标准下与真实的后验概率分布尽可能接近。

在变分自编码器中, 这一思想被用于对潜在变量的分布进行建模。与传统的自编码器不同, 变分自编码器对编码后的潜在表示引入了概率性, 即将其看作是从一个潜在分布中采样得到的。因此, 潜在变量在变分自编码器中被视为随机变量而非确定性值。

具体来说, VAE引入了两个关键部分:

1. **潜在变量的编码分布 (Encoder Distribution)**: 变分自编码器的编码器 (Encoder) 输出的不是一个确定的潜在表示, 而是潜在变量的概率分布。通常, 这个概率分布被假设为正态分布 (通常是多维的), 并且编码器输出的是该分布的参数。
2. **潜在变量的解码分布 (Decoder Distribution)**: 解码器 (Decoder) 接受从编码器中采样得到的潜在变量, 并试图将其解码为原始输入。这里的关键是, 解码器不仅仅是将潜在表示映射回输入, 而是建模了一个条件分布, 即给定潜在变量的条件下, 输入的条件分布。

通过引入概率性, VAE能够学习数据的连续、分布式表示, 并且具有一定的生成性质。此外, VAE在训练过程中通过最小化重构误差 (使重构的数据接近原始数据) 以及正则化KL散度 (用于衡量潜在分布与一个预先选择的先验分布之间的差异), 从而使学到的潜在表示具有更好的结构。



变分推断的基本思想是通过在某个参数化的分布族中寻找一个近似分布, 使其在某个标准下与真实的后验概率分布尽可能接近。这个近似分布被称为变分分布, 而变分推断的目标是最小化近似分布与真实后验分布之间的差异。

具体来说, 给定观察数据 X 和模型参数 θ , 我们想要计算后验分布 $p(\theta|X)$ 。变分推断引入一个变分分布 $q(\theta)$, 并通过最小化 $q(\theta)$ 与 $p(\theta|X)$ 的差异来近似真实的后验分布。这个差异通常使用KL散度 (Kullback-Leibler divergence) 来度量:

$$KL(q(\theta)||p(\theta|X)) = \int q(\theta) \log \left(\frac{q(\theta)}{p(\theta|X)} \right) d\theta$$

KL散度有不同形式, 自行查询了解。

变分推断中的最优化:

寻找一个近似分布 (**决策变量**) 使其在某个标准下 (**约束**) 与真实的后验概率分布尽可能接近 (**目标函数**)。

白话文版本:

目标----两个概率分布一样


约束----概率分布满足观测值

变量----参数化的分布


为什么VAE没有AE的缺点?

变分自编码器, Variational AE, VAE

• VAE怎么获得连续表示?



这里没有考虑权重



$$\text{loss} = \|x - \hat{x}\|^2 + \text{KL}[N(\mu_x, \sigma_x), N(0, I)] = \|x - d(z)\|^2 + \text{KL}[N(\mu_x, \sigma_x), N(0, I)]$$

AE中: 已知 x , 通过训练 (最小化loss) 获得函数 e 和 d , 分别为编码器和解码器。编码器 (函数 e) 把 x 编码为 z , 解码器 (函数 d) 把 z 解码为 $\hat{x}$ 。

VAE中: 已知 x , 通过训练 (最小化loss) 获得**概率分布 $p(z|x)$** 和 d , 分别为编码器和解码器。


编码器-概率分布: **根据概率分布 $p(z|x)$ 进行采样获得 z** , sampling是什么? 采样, 获得的数据满足某特定概率分布, 即获得的 z 的满足 p 分布, 如果 $p(z|x) \sim N(0, I)$, 可以想象采样得到的 z 就是分布在标准正态分布上的。

试想一下, 给定 x , 通过VAE获得概率分布后, 理论上每次随机采样获得 z 都可能不一样, 但是满足某个分布, 例如, 采集到的 $z = \mu + 0.01\delta$ 或 $\mu - 0.01\delta$ 。这样的好处就是训练后的VAE不像AE那般“一一对应”, 保证 z 的连续表示能力。


再联想一项, 如果方差等于0, 是不是VAE就变AE了。每次采样都是 z 。

VAE另一种理解方式

- VAE是生成模型的一种，AE不是，为什么VAE是？




- 生成模型试图构建 $p(x)$ 。例如，如果我们知道 x （分子smiles）是正态分布的，是不是可以从该分布任意采样，获得任意分子。显然，AE是无法满足的，VAE可以。
- VAE解决思路是： $p(x)$ 无法直接得到，可以通过跟已知分布 $p(z)$ 的关系获得。



$p(x)$ 可以用 z 表示， z 满足正态分布。
这个积分公式不理解需要去查查概率论。 $p(x/z)$ 表示观测到 z 的情况下， x 的概率，积分就是累加，把所有可能观测到的 z 都考虑了。

VAE, 一些数学推导


Note: 解码、编码为概率模型



$$p(x) = \int p(z)p(x|z)dz$$

$p(z)$ 和 $p(x|z)$ 都是参数化分布(parametric distribution)


VAE, 一些数学推导



$$p(x) = \int p(z)p(x|z)dz \quad p(z|x) = \frac{p(x|z)p(z)}{p(x)}$$

$p(z)$ 和 $p(x|z)$ 都是参数化分布(parametric distribution), 上述过程无法直接求解。

VAE, 一些数学推导



$$p(x) = \int p(z)p(x|z)dz \quad p(z|x) = \frac{p(x|z)p(z)}{p(x)}$$


$p(z)$ 和 $p(x|z)$ 都是参数化分布(parametric distribution), 上述过程无法直接求解。

VAE用 $q(z|x)$ 近似 $p(z|x)$, 那么目标就是最小化KL散度, $\min KL(q(z|x), p(z|x))$

$q(z|x) \sim N(g(x), h(x))$, 表示该分布的均值 $g(x)$ 为 x 的函数, 方差 $h(x)$ 也为 x 的函数。

VAE, 一些数学推导

$$q(z|x) = q_x(z) \\ \sim N(g(x), h(x))$$



$$\min KL(q(z|x), p(z|x)) \quad \text{用 } q_x(z) \text{ 表示 } q(z|x), \quad z \sim q_x \text{ 表示从该分布中对 } z \text{ 采样}$$

$$(g^*, h^*) = \arg \min_{(g, h) \in G \times H} KL(q(z|x), p(z|x))$$

$$= \arg \min_{(g, h) \in G \times H} \left(\mathbb{E}_{z \sim q_x} (\log(q_x(z))) - \mathbb{E}_{z \sim q_x} \left(\log \frac{p(x|z)p(z)}{p(x)} \right) \right) \quad \text{最后一项为常数}$$

$$= \arg \min_{(g, h) \in G \times H} \left(\mathbb{E}_{z \sim q_x} (\log(q_x(z))) - \mathbb{E}_{z \sim q_x} (\log(p(z))) - \mathbb{E}_{z \sim q_x} (\log(p(x|z))) + \mathbb{E}_{z \sim q_x} (\log(p(x))) \right)$$


$$= \arg \min_{(g, h) \in G \times H} \left(KL(q_x(z), p(z)) - \mathbb{E}_{z \sim q_x} (\log(p(x|z))) \right)$$

$$= \arg \min_{(g, h) \in G \times H} \left(KL(q_x(z), p(z)) - \mathbb{E}_{z \sim q_x} \left(-\frac{\|x - f(z)\|^2}{2c} \right) \right) \quad \text{正态分布的期望, 约了一些常数项}$$

$$= \arg \min_{(g, h) \in G \times H} \left(KL(N(g(x), h(x)), N(0, I)) + \mathbb{E}_{z \sim q_x} \left(\frac{\|x - f(z)\|^2}{2c} \right) \right)$$

VAE, 一些数学推导

$$q(z|x) = q_x(z) \\ \sim N(g(x), h(x))$$



$\min KL(q(z|x), p(z|x))$ 用 $q_x(z)$ 表示 $q(z|x)$, $z \sim q_x$ 表示从该分布中对 z 采样

$$(g^*, h^*) = \arg \min_{(g, h) \in G \times H} KL(q(z|x), p(z|x))$$

$$= \arg \min_{(g, h) \in G \times H} \left(KL(N(g(x), h(x)), N(0, I)) + \mathbb{E}_{z \sim q_x} \left(\frac{\|x - f(z)\|^2}{2c} \right) \right)$$


根据推导可以发现上面第一项为 $q(z|x)$ 和标准正态分布的KL散度, 后面一项为就是输入 x 和解码后均值 $f(z)$ 的差的平方 (解码评价指标)。上面公式还有一个难点: 后一项中 $z \sim q_x$ 这个采样过程无法求导, 解决问题需要用再参数化技巧 reparametrisation trick: $z = g(x) + h(x)\zeta$, $\zeta \sim N(0, I)$

$$= \arg \min_{(g, h, f) \in G \times H \times f} \left(KL(N(g(x), h(x)), N(0, I)) + \mathbb{E}_x \left(\frac{\|x - f(g(x) + h(x)\zeta)\|^2}{2c} \right) \right)$$

上面这个优化问题最终成为获得三个神经网络 g, h, f 的优化问题, 上式KL写出近似解析式, 期望通过给定的样本 x 也很容易求解。

系数 c 可以KL散度和解码评价指标两个目标的权重。

reparametrisation trick



如果根据均值和标准差直接采用的过程无法反向传播。
简单理解：采样得到的 z 不包含 dz/dx 的信息。用数值微分或许能获得，但是不适用。

再参数化技巧， $\frac{dz}{dx} = \frac{dg}{dx} + \zeta \times \frac{dh}{dx}$
这种方法在自动微分技术下很容易获得梯度信息，从而可以用于反向传播。